

Индивидуальный проект «Python для автоматизации анализа данных»

В рамках данного задания вам предлагается выбрать и проанализировать один из датасетов с использованием изученных библиотек Python. В отличие от обычных заданий, проверка работы выполняется вручную преподавателем, и по результатам вы получите развернутый отзыв.

Задание выполняется на оценку и имеет дедлайн. При сдаче работы с опозданием до 10 календарных дней включительно применяется штраф в размере 20%. По истечении этого срока работы на проверку не принимаются.

Пожалуйста, внимательно ознакомьтесь с условиями задания. В случае возникновения вопросов вы можете обратиться к куратору, задав вопрос в чате программы.

Для выполнения задания рекомендуем воспользоваться [шаблоном](#)

Желаем успешного выполнения задания!

Список датасетов для выбора

Для выполнения задания выберите один из приведенных ниже датасетов.

1. Продажи игр

<https://www.kaggle.com/datasets/gregorut/videogamesales>

Цель: найти наиболее перспективный жанр игры для потенциальной разработки.

Гипотеза: есть жанр игр (возможно в связке с платформой или что-то еще), который продается лучше.

2. Список ноутбуков с параметрами для выбора

<https://www.kaggle.com/datasets/rajugc/laptop-selection-dataset>

Цель: мы хотим выпустить ноутбук, но для этого нам нужно понимать оптимальные параметры для него, следовательно основываясь на пользовательском рейтинге нам нужно выбрать оптимальную ОС, размер хранилища и т.п.

Гипотеза: если мы выпустим ноутбук с наиболее востребованными характеристиками, то он будет лучше продаваться.

3. Список персонажей DC Comics

<https://www.kaggle.com/datasets/arunasivapragasam/dc-comics>

Мы запускаем свою линейку комиксов и нам нужно определить паттерн (набор черт, например: мужчина с голубыми глазами, засекреченной личностью и при этом злодей) пяти наиболее популярных (по числу появлений) персонажей.

Гипотеза: самые популярные персонажи часто похожи и можно из них выделить некие паттерны, на которых мы можем опираться при создании персонажей.

Что нужно сделать

Итак, после того, как вы выбрали датасет, можно приступить к выполнению задания.

Требования к выполнению задания:

- все пункты выполнять в самостоятельно созданном **Jupyter-ноутбуке**, который будет являться результатом вашей работы. Готовый ноутбук после выполнения заданий вы сдадите на проверку;
- следовать пунктам задания, поясняя выполняемые действия текстом;
- делать выводы по результатам анализа — один из критериев оценки работы;
- если возникнут трудности и вопросы, напишите пояснение в ноутбуке, где возникли затруднения, и в чем они проявляются.

Последовательность выполнения заданий:

1. Проверьте качество данных:

- a. проверьте типы данных колонок и приведите их к нужному типу (например, даты к типу `datetime`);
- b. проверьте наличие пропущенных значений и обработайте их (например, заполните по какому-либо принципу или удалите строки с пропущенными значениями);
- c. проверьте данные на наличие дубликатов, и, если необходимо, удалите их.

2. Рассчитайте основные статистические показатели для числовых переменных, такие как среднее, медиана и стандартное отклонение. Другие статистические показатели также могут быть рассчитаны в зависимости от конкретных целей и задач анализа данных. Сделайте вывод по результатам.

3. Постройте графики, которые считаете наиболее релевантными для анализа данных. Графики должны быть информативными и помочь вам лучше понять данные. При необходимости введите дополнительные колонки в исходный датафрейм. После построения графиков проанализируйте полученные результаты и сделайте выводы (например, какие данные имеют наибольшую значимость, какие переменные влияют на результаты). При необходимости доработайте данные на этом этапе.

4. Вычислите матрицу корреляции и постройте heatmap для нее. Сделайте выводы о взаимосвязях, обнаруженных в данных.

5. Сделайте общий вывод по исследуемому датасету. Предложите возможные способы применения полученных результатов анализа данных.

Требования к формату сдачи проекта

Для сдачи индивидуального проекта необходимо строго соблюдать следующие требования:

- Все задания должны быть выполнены в **Jupyter-ноутбуке**. Это позволяет отразить как ход вычислений, так и графическую визуализацию результатов (при необходимости).
- Решение должно быть оформлено в виде последовательности **кодовых и markdown-ячеек**, где:
 - каждое задание сопровождается кратким текстовым пояснением;
 - приведены промежуточные расчеты (если они есть);
 - даны **выводы по каждому этапу анализа**.
- Если при выполнении задания возникли затруднения, необходимо **написать об этом в соответствующем месте ноутбука**, пояснив, что именно вызвало трудности.
- При желании вы можете воспользоваться шаблоном ноутбука с уже включенными markdown-ячейками — он поможет структурировать работу.
- Сдача работы в любом другом формате (например, Word-документ, PDF и т.п.) **не допускается**.
- Файл с проектом должен быть назван в следующем формате: **Фамилия-Имя-Номер датасета.ipynb**.
Например: Иванов-Петр-Датасет 1.ipynb. Это упростит проверку и систематизацию работ.

!!! Работа должна быть сдана до установленного дедлайна. После истечения срока возможность загрузить проект будет закрыта.

Критерии оценки

Оценка работы будет выполняться по трем группам критериев:

1. Выполнение технической части задания:
 - Анализ структуры датасета и предобработка данных (макс 1 балл)
 - Вычисление описательных статистик (макс 1 балл)
 - Визуализация результатов анализа данных (макс 1 балл)
 - Определение наличия/отсутствия взаимосвязи между параметрами датасета (макс 1 балл)
 - Личные идеи к решению поставленной задачи и их реализация (макс 1 балл)
2. Интерпретация результатов исследования — наличие сделанных выводов, их корректность и непротиворечивость:
 - Интерпретация этапа предобработки (макс 2 балла)
 - Интерпретация этапа вычисления статистик (макс 2 балла)
 - Интерпретация этапа визуализации (макс 2 балла)
 - Общий вывод по датасету, рекомендации к использованию (макс 2 балла)
3. Качество кода и оформления работы:
 - Качество кода: понятность, читаемость (макс 1 балл)
 - Оформление работы (макс 1 балл)

Проверка работ займет 2,5-3 недели.

Важно! Задание является альтернативным по отношению к итоговому практическому заданию 11.2 по текущему модулю. В общей оценке за курс максимально вы можете получить 15 баллов.

Дополнительные материалы

1. [Getting started — pandas 1.5.3 documentation](#)
2. [Six Steps of Data Analysis Process - GeeksforGeeks](#)
3. [Моя шпаргалка по pandas / Хабр](#)
4. [Lesson 1. EDA with Pandas | Kaggle](#)